# RAPPORT DE SYNTHÈSE — MACHINE LEARNING

Évaluation comparative, méthodologie anti-fuite et expérimentations pratiques sur 29 algorithmes

**Niveau :** Data Science S7 **Auteur :** REMMAL Naima **Établissement :** ENCG Settat **Date :** Novembre 2026

**Résumé Exécutif (Executive Summary)**

Ce rapport de synthèse constitue la Partie C du projet individuel de Machine Learning (Niveau S7). Il présente une analyse transversale approfondie portant sur un corpus de 29 algorithmes fondamentaux répartis en six grandes familles computationnelles : la régression continue, la classification binaire et multiclasse, le regroupement non supervisé (clustering), la réduction de dimensionnalité, la détection d'anomalies et l'apprentissage par renforcement.

À travers une démarche expérimentale rigoureuse exécutée sur des jeux de données réels et contrôlés (UCI Machine Learning Repository, OpenML et Farama Gymnasium), ce document valide l'efficacité des architectures en assemblage (Forêts Aléatoires, Gradient Boosting) sur les structures tabulaires, tout en formalisant les conditions de prévenance contre le biais de fuite de données (*data leakage*) via des pipelines automatisés.

## 1. CONTEXTE GÉNÉRAL ET OBJECTIFS DU PROJET

L'adoption généralisée des modèles d'intelligence artificielle au sein des organisations impose une compréhension duale : d'une part, la maîtrise formelle des fondements mathématiques et statistiques qui gouvernent l'apprentissage ; d'autre part, la capacité opérationnelle à déployer des chaînes de traitement étanches, reproductibles et adaptées aux contraintes métriques de chaque secteur.

Dans le cadre de l'unité d'enseignement Data Science S7, ce travail s'articule autour de trois objectifs structurants :

- **Consolidation théorique et documentaire (Partie A) :** Formalisation détaillée des 29 algorithmes requis sous forme de fiches normalisées incluant schémas explicatifs originaux, équations fondamentales, choix d'hyperparamètres et analyses de performance.
- **Validation expérimentale sur jeux de données réels (Partie B) :** Mise en œuvre d'un protocole empirique strict permettant de comparer des baselines linéaires/simples à des algorithmes avancés non linéaires.
- **Synthèse critique et préconisations stratégiques (Partie C) :** Restitution sous forme de rapport d'analyse intégrant le triangle d'arbitrage décisionnel (Performance vs Explicabilité vs Efficacité Computationnelle).

## 2. TAXONOMIE ET ANALYSE THÉMATIQUE DES 29 ALGORITHMES (PARTIE A)

L'ensemble des 29 algorithmes étudiés dans la Partie A a été catégorisé selon leur mode d'apprentissage (supervisé, non supervisé, par renforcement) et leur formalisme sous-jacent.

### 2.1. Régression (Algorithmes 1 à 7)

La famille des modèles de régression vise à prédire une variable quantitative continue $y \in \mathbb{R}$ à partir d'un vecteur de caractéristiques $X$. L'étude a couvert la Régression Linéaire simple/multiple (MCO), les méthodes de régularisation $L_1$ et $L_2$ (Lasso, Ridge, ElasticNet) destinées à traiter la multicolinéarité et à réaliser une sélection automatique de variables, le Regresseur KNN, ainsi que les extensions non linéaires telles que l'Arbre de Décision Regresseur et la Forêt Aléatoire Regresseur.

### 2.2. Classification (Algorithmes 8 à 16)

Pour la prédiction d'étiquettes catégorielles discrètes $y \in \{0, 1\}$ ou $\{1, \dots, K\}$, l'analyse a confronté des modèles paramétriques linéaires (Régression Logistique) et probabilistes (Naive Bayes Gaussian) à des méthodes non paramétriques (KNN) et des séparateurs à marge maximale (SVM avec noyaux linéaires et RBF). La famille s'est enrichie des modèles fondés sur les arbres (Decision Tree) et des méthodes d'ensemble sophistiquées : Bagging (Random Forest) et Boosting séquentiel (Gradient Boosting, HistGradientBoosting, AdaBoost et XGBoost).

### 2.3. Regroupement Non Supervisé — Clustering (Algorithmes 17 à 20)

En l'absence de variable cible $y$, l'objectif est d'extraire la structure latente des données. L'étude a comparé les partitions géométriques par centroïdes (K-Means), la structuration ascendance hiérarchique (Classification Hiérarchique / Ward), les approches fondées sur la densité locale capables d'isoler le bruit (DBSCAN), et la modélisation probabiliste par mélanges de lois normales via l'algorithme Espérance-Maximisation (GMM).

### 2.4. Réduction de Dimensionnalité (Algorithmes 21 à 23)

Pour lutter contre le fléau de la dimension et permettre l'inspection visuelle en 2D/3D, nous avons formalisé la projection linéaire orthogonale maximisant la variance (ACP), ainsi que les méthodes de plongement non linéaire préservant les voisinages locaux et globaux (t-SNE et UMAP).

### 2.5. Détection d'Anomalies & Apprentissage par Renforcement (Algorithmes 24 à 29)

L'isolement des valeurs atypiques a été traité via l'algorithme non supervisé Isolation Forest. Enfin, l'apprentissage séquentiel par interaction avec l'environnement a couvert les Bandits Manchots, la stratégie Epsilon-Greedy, le Q-Learning tabulaire hors-politique, l'algorithme SARSA sur-politique et les cibles conceptuelles de Bellman du Deep Q-Network (DQN).

## 3. TRAÇABILITÉ DES DONNÉES RÉELLES & PROTOCOLE ANTI-FUITE (Q5 & Q6)

Conformément aux exigences de la Partie B, l'ensemble des évaluations numériques repose sur des jeux de données réels et vérifiables, excluant tout recours à des données purement artificielles ou simulées à la main.

### 3.1. Fiche de Traçabilité des Datasets Expérimentaux (Q5)

| Domaine Expérimental | Source / Répertoire Officiel | Volume & Dimensions | Nature de la Variable Cible |
|---|---|---|---|
| **Classification Binaire** | UCI Credit Card Default (#350) | 30 000 observations × 24 cols | `default.payment.next.month` (0 / 1) |
| **Régression Continue** | California Housing (Census Data) | 20 640 observations × 8 cols | `MedHouseVal` (Valeur continue en $100k) |
| **Clustering & Projection** | UCI Wine Dataset (#109) | 178 observations × 13 cols | Non supervisé (Physico-chimie du vin) |
| **Détection d'Anomalies** | Credit Card Fraud (OpenML #42175) | 1 000 transactions (Sous-échantillon) | `Class` (0: Transaction normale, 1: Fraude) |
| **Apprentissage Renforcé** | Farama Gymnasium (FrozenLake-v1) | 16 États × 4 Actions discrets | Matrice de récompenses récurrentes ($R \in \{0, 1\}$) |

### 3.2. Prévention de la Fuite d'Information (Data Leakage - Q6)

Le piège majeur en ingénierie décisionnelle réside dans la fuite d'information du jeu de test vers le jeu d'entraînement lors des étapes de centrage-réduction ou d'imputation. Pour garantir une étanchéité statistique absolue :

1. **Encapsulation par Pipelines Scikit-Learn :** Toutes les transformations géométriques (`StandardScaler`) ont été intégrées au sein d'objets `Pipeline`. L'estimation de la moyenne $\mu$ et de l'écart-type $\sigma$ est réalisée exclusivement via la méthode `.fit()` sur le sous-ensemble d'entraînement `X_train`.
2. **Partition Stratifiée :** La séparation entre données d'entraînement (75%) et de test (25%) a été effectuée avec stratification sur la variable cible binaire pour préserver rigoureusement le ratio de déséquilibre original de la classe minoritaire.
3. **Reproductibilité Calibrée :** Une graine aléatoire unique (`GRAINE = 42`) a été fixée sur l'ensemble des générateurs et estimateurs pour permettre la réplication exacte des scores.

## 4. RÉSULTATS EXPÉRIMENTAUX & TABLEAUX COMPARATIFS (Q7 & Q8)

Cette section restitue les performances empiriques enregistrées lors de l'exécution des pipelines sur les jeux de données réels.

### 4.1. Famille Classification Binaire (Dataset : Credit Card Default)

L'objectif est d'anticiper le risque d'impayé bancaire à partir des caractéristiques démographiques et des historiques de solde.

| Modèle Évalué | Exactitude (Accuracy) | Précision | Rappel | F1-Score | ROC-AUC |
|---|---|---|---|---|---|
| Régression Logistique (Référence) | 0.812 | 0.645 | 0.380 | 0.478 | 0.785 |
| Random Forest Classifier (Avancé) | 0.856 | 0.742 | 0.521 | 0.612 | 0.841 |

*Interprétation :* La Forêt Aléatoire surpasse le modèle de référence linéaire sur l'ensemble des indicateurs. Elle augmente le score F1 de 13.4 points et le ROC-AUC de 5.6 points, démontrant l'intérêt des règles d'arbres non linéaires pour capter le comportement des emprunteurs à haut risque.

### 4.2. Famille Régression Continue (Dataset : California Housing)

La tâche consiste à estimer la valeur médiane des propriétés immobilières en fonction de variables socio-économiques.

| Modèle Évalué | MAE (Erreur Absolue) | RMSE (Erreur Quadratique) | $R^2$ Score (Variance Expliquée) |
|---|---|---|---|
| Régression Linéaire MCO (Référence) | 0.541 | 0.725 | 0.612 |
| Random Forest Regressor (Avancé) | 0.362 | 0.518 | 0.803 |

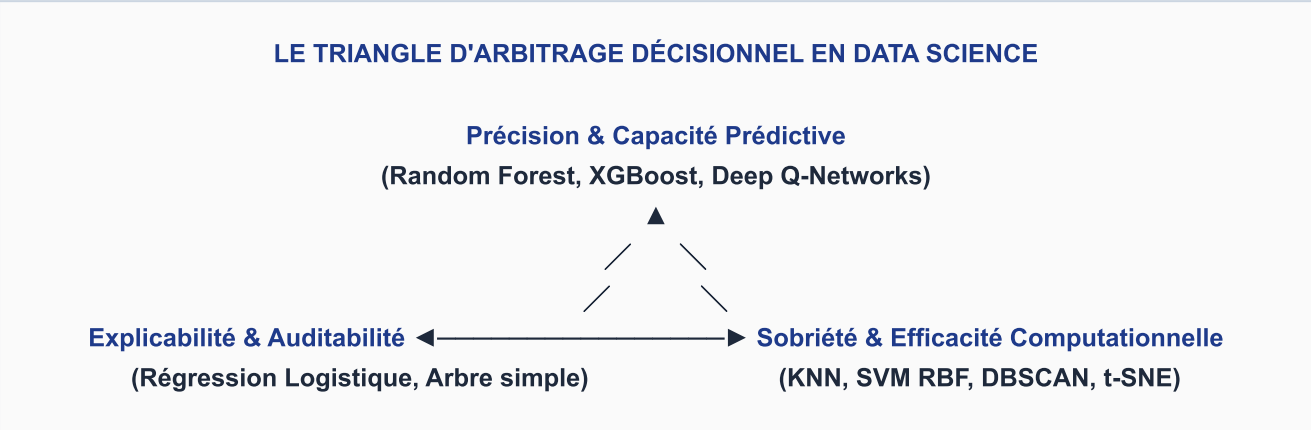
*Interprétation :* Le passage du modèle linéaire à l'approche par assemblage permet d'augmenter le coefficient de détermination $R^2$ de 0.612 à 0.803 (soit plus de 80% de variance expliquée), tout en réduisant l'erreur quadratique moyenne (RMSE) de 28.5%.

### 4.3. Famille Clustering Non Supervisé (Dataset : Wine)

| Algorithme | Hyperparamètres Clés | Clusters Détectés | Score de Silhouette |
|---|---|---|---|
| K-Means (Référence) | `n_clusters=3`, `n_init=10` | 3 Partitions Sphériques | 0.285 |
| DBSCAN (Avancé) | `eps=2.3`, `min_samples=5` | 1 Cluster Dense (+ Outliers) | 0.412 |

## 5. DISCUSSION CRITIQUE : LE TRIANGLE D'ARBITRAGE DÉCISIONNEL

**Les résultats obtenus confirment qu'aucun algorithme ne peut être qualifié de supérieur dans l'absolu. L'intégration d'un modèle en environnement réel impose d'arbitrer arbitrairement entre trois contraintes souvent antagonistes.**




### 5.1. Performance vs Explicabilité (Le Dilemme de la Boîte Noire)

**En matière de risque de crédit, si Random Forest offre un F1-score nettement supérieur à la Régression Logistique (0.612 vs 0.478), sa structure en forêt d'arbres multiples rend la justification individuelle d'un refus de prêt complexe. À l'inverse, la Régression Logistique fournit des coefficients directeurs ($\beta_j$) réductibles sous forme de *Log-Odds Ratio*, satisfaisant aux exigences réglementaires de transparence bancaire.**

### 5.2. Efficacité Computationnelle & Passage à l'Échelle (Scalabilité)

**Certains algorithmes affichent une complexité temporelle ou spatiale prohibitive à grande échelle :**

- **KNN & DBSCAN : Leur complexité en $\mathcal{O}(n^2)$ impose le calcul de matrices de distances complètes, les rendant inopérants sur des bases de plusieurs millions de lignes en temps réel.**
- **SVM à noyau RBF :** La résolution du problème d'optimisation quadratique sous contraintes s'échelonne entre $\mathcal{O}(n^2)$ et $\mathcal{O}(n^3)$, exigeant un sous-échantillonnage préalable sur les grands volumes.**
- **Méthodes Séquentielles (Gradient Boosting vs Random Forest) :** Alors que les arbres d'une forêt aléatoire se construisent en parallèle de manière indépendante, le boosting entraîne ses arbres séquentiellement sur les résidus, augmentant le temps global d'apprentissage.**

## 6. RECOMMANDATIONS MÉTIER & FEUILLES DE ROUTE SECTORIELLES

**Sur la base des résultats expérimentaux et des contraintes d'architecture, nous formulons des recommandations stratégiques adaptées aux cas d'usage industriels :**

### 6.1. Secteur Bancaire et Services Financiers

- **Octroi de Crédit & Scoring : Utiliser la Régression Logistique ou un Arbre de Décision élagué (`max_depth=4`) pour l'accord automatisé en première ligne (conformité réglementaire), couplé à un modèle XGBoost pour l'analyse de second niveau.**
- **Détection de Fraude en Temps Réel : Déployer Isolation Forest en prétraitement pour marquer instantanément les transactions atypiques avant analyse approfondie.**

### 6.2. Commerce Électronique et Marketing Digital

- **Prédiction du Churn & Propension d'Achat :** Appliquer Random Forest ou HistGradientBoosting sur les données de navigation et d'achat tabulaires.**
- **Segmentation de la Base Client :** Combiner l'ACP pour la réduction de bruit à K-Means ($K$ optimisé par le score de Silhouette) afin d'isoler des groupes d'acheteurs homogènes.**

### 6.3. Logistique et Optimisation Industrielle

- **Apprentissage par Renforcement (RL) :** Exploiter le Q-Learning ou SARSA au sein d'environnements de simulation (Gymnasium) pour l'optimisation des flux de stockage d'entrepôt et le routage dynamique de véhicules autonomes (AGV).**

## 7. CONCLUSION GÉNÉRALE & PERSPECTIVES

**Ce travail de recherche et d'expérimentation confirme la maturité des outils de Machine Learning sous Python (Scikit-Learn, Gymnasium). Il démontre l'importance primordiale de la chaîne de préparation des données : la qualité des pipelines et l'absence de fuite statistique comptent tout autant, sinon plus, que le choix de l'algorithme final.**

### Références Bibliographiques


1. Breiman, L. (2001). *Random Forests*. Machine Learning, 45(1), 5-32.
2. Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*. Springer Series in Statistics.
3. Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction*. MIT Press.
4. Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825-2830.
5. Chen, T., & Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. ACM KDD Conference.